

Alcune delle domande di seguito si riferiscono al dataframe **df**, nel file **df_30October.RData**, che contiene dati raccolti su un campione di 1960 app per Android, rispetto alle variabili:

installs: variabile numerica che misura il numero di installazioni della app

rating: variabile qualitativa che misura il rating della app, con modalità **low**, **medium** and **high**

genres: variabile qualitativa che misura il tipo di app, con modalità **Action**, **Books**, **Education**, **Entertainment** e **Social**

reviews: variabile numerica che misura il numero di recensioni della app



Esercizio 1 (5 punti)

Si faccia riferimento al dataframe **df**.

a) Possiamo dire che, a livello del campione, il numero di installazioni delle app (variabile **installs**) ha distribuzione approssimativamente simmetrica? Si giustifichi la risposta facendo riferimento a opportuni grafici e misure di sintesi.

Dal boxplot, dall'istogramma e dai cinque numeri di sintesi si può osservare come, al livello di campione, **installs** ha una distribuzione asimmetrica (obliqua) a sinistra. La differenza tra primo quartile e minimo (6200-1400) è superiore alla differenza tra massimo e terzo quartile (9000-7525). Anche la differenza tra mediana e primo quartile (6977- 6200) è inferiore alla differenza tra terzo quartile e mediana (7525 -6977). Ci sono outlier nel lato dei valori bassi della distribuzione, che contribuiscono alla a generare la coda a sinistra nell'istogramma.

```
boxplot(df$installs), hist(df$installs, freq=FALSE), summary(df$installs),
```



b) Si riporti il numero di app che, nel campione, hanno un numero di installazioni (variabile **installs**) inferiore a 6200; si faccia riferimento ai cinque numeri di sintesi e al boxplot.

6200 è il primo quartile della distribuzione di **installs**, il numero di app con installazioni inferiori a 6200 è quindi $0.25 \cdot 1960 = 490$

c) Si riporti la percentuale di app che hanno rating basso (**rating=low**), tra le app di tipo social (**genres=Social**). Si arrotondi la risposta alla seconda cifra decimale.

27.52% delle app hanno rating basso (**rating=low**), tra quelle di tipo social (**genres=Social**)

```
tab = table(df$rating,df$genres),
```

```
prop.table(tab,2)
```

d) Possiamo concludere che, a livello del campione, il rating delle app (variabile **rating**) dipenda dal tipo di app (variabile **genres**)? Si giustifichi la risposta.

Al punto precedente abbiamo ricavato le distribuzioni condizionali di **rating** dato **genres**. Dal loro confronto possiamo concludere che, a livello di campione, **rating** dipende da **genres**. Ad esempio, 9.52% delle app di tipo **Action** hanno rating **high**, mentre 37.5% delle app di tipo **Books** hanno rating **high**.

e) Possiamo dire che a livello del campione c'è una forte associazione lineare tra il numero di installazioni (variabile **installs**) e il numero di recensioni (variabile **reviews**)? Si giustifichi la risposta con riferimento ad un opportuno indice statistico.

Il coefficiente di correlazione tra **installs** e **reviews** è uguale a 0.1286. Tra le due variabili c'è quindi una bassa correlazione positiva.

```
cor(df$installs,df$reviews)
```

Esercizio 2 (5 punti)

C'è una probabilità del 30% che un individuo estratto a caso dalla popolazione dei residenti nella regione R appartenga a un gruppo ecologista. Si estraggono a caso 500 residenti nella regione R.

a) Si riporti la varianza del numero di residenti, tra i 500 estratti a caso, che appartengono a un gruppo ecologista

Sia X_i una variabile aleatoria che assume valore 1 se il residente estratto a caso appartiene a un gruppo ecologista e 0 altrimenti, $X_i \sim \text{Bern}(0.3)$. Associati ai 500 residenti estratti a caso abbiamo il campione $(X_1, \dots, X_{500})$ di variabili i.i.d $\sim \text{Bern}(0.3)$.

$T = \sum_{i=1}^{500} X_i$ è il numero di residenti, tra i 500 estratti a caso, appartenenti a un gruppo ecologista.

Sia ha

$$\text{Var}(T) = 500 \cdot 0.3 \cdot 0.7 = 105$$

b) Si riporti la probabilità che al più 150 tra i 500 estratti a caso appartengano al gruppo ecologista.

La probabilità richiesta è $\Pr(T \leq 150)$. T per il teorema centrale del limite ha distribuzione approssimativamente normale con valore atteso $E(T) = 500 \cdot 0.3 = 150$ e varianza 105. 150 è quindi anche la mediana di T, per cui $\Pr(T \leq 150) = 0.5$.

c) La probabilità calcolata al punto precedente è esatta o approssimata? Si giustifichi la risposta.

La probabilità calcolata è approssimata perché T, per il teorema centrale del limite, ha distribuzione approssimativamente normale.

d) Si riporti il quantile di ordine 0.4 (quarantesimo percentile) della distribuzione della proporzione di residenti che, tra i 500 estratti a caso, appartengono ad un gruppo ecologista. Si arrotondi il valore alla quarta cifra decimale.

La proporzione di residenti che, tra i 500 estratti, appartengono ad un gruppo ecologista è $\hat{P} = \frac{\sum_{i=1}^{500} X_i}{500}$. Per il teorema centrale del limite ha una distribuzione approssimativamente normale con valore atteso 0.3 e varianza $\frac{0.7 \cdot 0.3}{500}$.
 Il 40-esimo percentile è 0.2948 e si ottiene come segue:
`qnorm(0.4, 0.3, sqrt(0.7*0.3/500)) = 0.2948079`

Esercizio 3 (5 punti)

Si faccia riferimento a **df**.

a) Si consideri la variabile **reviews**.

a1) Si riporti la stima della media del numero di recensioni di tutte le app per Android (media della popolazione di **reviews**) e il corrispondente standard error. Si arrotondino i valori alla seconda cifra decimale.

La stima della media è il valore osservato della media campionaria, 113451.6, e lo standard error è dato da $\frac{s}{\sqrt{1960}} = 259708.5/\sqrt{1960}=5866.218$.
 I due valori si ottengono come segue
`mean(df$reviews) , sd(df$reviews)/sqrt(1960)`

a2) Se si rimuovessero dal campione 100 app, lo standard error diminuirebbe, aumenterebbe o resterebbe inalterato? Si giustifichi la risposta.

Lo standard error dipende dal valore osservato dello scarto quadratico medio campionario. Se si rimuovono 100 unità, non sappiamo quale sarà lo scarto quadratico medio di **reviews** a livello del nuovo campione e quindi non è possibile prevedere come si modifica lo standard error.

b) Si riporti l'intervallo di confidenza di livello 0.99 per la proporzione di app che hanno un rating **low** (variabile **rating**). Si arrotondino gli estremi alla quarta cifra decimale.

L'intervallo di confidenza di livello $(1 - \alpha)$ sulla proporzione p di app che hanno un rating **low** è

$$[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}]$$

In questo caso $\hat{p}$ è la frequenza relativa del valore **low**, che si ottiene come segue
`tab2 = table(df$rating) , prop.table(tab2) .`

Si ha quindi

$$\hat{p} = 0.2878, z_{\alpha/2} = \text{qnorm}(1-0.01/2) = \text{qnorm}(0.995) = 2.576$$

$$[0.2878 - 2.576 \sqrt{\frac{0.2878(1-0.2878)}{1960}}, 0.2878 + 2.576 \sqrt{\frac{0.2878(1-0.2878)}{1960}}] = [0.2615, 0.3141]$$