

Alcune delle domande di seguito si riferiscono al dataframe **df**, nel file **df_Jan8.RData**, che contiene dati raccolti su un campione di 500 libri, rilevati su più anni, rispetto alle seguenti variabili:

Genre: variabile qualitativa che indica il genere del libro, con modalità **Fiction, Mystery, Romance, Science Fiction**

Price: variabile numerica che indica il prezzo del libro

Sales: variabile numerica che indica le vendite totali del libro

Promotion: variabile qualitativa con modalità YES nel caso di una campagna promozionale forte e NO altrimenti

Reviews: variabile numerica che indica le recensioni medie dei lettori

Alcune delle domande di seguito si riferiscono al dataframe **df**, nel file **df_Jan8.RData**, che contiene dati raccolti su un campione di 500 libri, rilevati su più anni, rispetto alle seguenti variabili:

Esercizio 1 (5 punti)

Si faccia riferimento al dataframe **df**.



a) Si descriva la forma della variabile **Sales** a livello del campione. Si faccia riferimento a opportuni grafici e misure di sintesi. Sono presenti outlier? E nel caso quanti?

In base al boxplot, all'istogramma (riportati di seguito) e ai cinque valori di sintesi, possiamo dire che Sales a livello del campione ha una distribuzione approssimativamente simmetrica e campanulare. La differenza tra il primo quartile e il minimo ($2917-1096=1821$) è simile alla differenza tra il massimo e la mediana ($5807-4064=1743$). Lo stesso si può dire se si confronta la differenza tra mediana e primo quartile e ($3535-2917=618$) con la differenza tra terzo quartile e mediana ($4064-3535=529$). Inoltre, la differenza tra primo quartile e minimo (1821) è maggiore della differenza tra mediana e primo quartile (529).

Ci sono 3 outliers.

```
> summary(df$Sales)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1096	2917	3535	3493	4064	5807



b) Si riporti la percentuale di libri che a livello del campione sono di genere **Fiction** (**Genre=Fiction**), tra quelli senza una forte campagna promozionale (**Promotion = NO**). Si arrotondi il valore alla seconda cifra decimale.

25.53% è la percentuale di libri che a livello del campione sono di genere **Fiction** (**Genre=Fiction**), tra quelli che hanno avuto una forte campagna promozionale (**Promotion = NO**).

```
> tab1 = table(df$Genre,df$Promotion)
> prop.table(tab1,2)
```

	NO	YES
Fiction	0.2553191	0.2339623
Mystery	0.2297872	0.2037736
Romance	0.2340426	0.2528302
Science Fiction	0.2808511	0.3094340

c) Si riporti la percentuale di libri che sono di genere **Fiction** o **Science Fiction** (variabile **Genre**) e con forte campagna promozionale (**Promotion=Yes**).

28.8% ($0.288=0.124+0.164$) è la percentuale di libri che sono di genere **Fiction** o **Science Fiction** (variabile **Genre**) e con forte campagna promozionale (**Promotion=Yes**).

```
> tab1 = table(df$Genre,df$Promotion)
> prop.table(tab1)
```

	NO	YES
Fiction	0.120	0.124
Mystery	0.108	0.108
Romance	0.110	0.134
Science Fiction	0.132	0.164

d) Possiamo concludere che a livello del campione c'è una debole associazione lineare tra **Sales** e **Price**? Si giustifichi la risposta riferendosi ad un opportuno indice statistico.

Valutiamo la associazione lineare a mezzo del coefficiente di correlazione, uguale a 0.7081. Tra le due variabili c'è una forte associazione lineare positiva.

```
cor(df$Sales,df$Price)
```

e) Si confronti la variabilità di **Reviews** nei quattro gruppi determinati da **Genre** ricorrendo ad un opportuno indice di sintesi.

Possiamo confrontare il coefficiente di variazione di **Reviews** nei 4 gruppi. Come si può osservare il coefficiente di variazione ha valori molto simili nei gruppi, per cui la variabilità è simile.

```
> tapply(df$Reviews,df$Genre,sd)/tapply(df$Reviews,df$Genre,mean)
Fiction      Mystery      Romance      Science Fiction
0.1348212    0.1463404    0.1347192    0.1378293
```

Esercizio 2 (5 punti)

Si intende spiegare la variabilità di **Sales** in base a tutte le altre variabili (**Genre**, **Price**, **Reviews**, **Promotion**) mediante un modello di regressione lineare multipla.

a)

a1) Possiamo concludere che **Promotion** è significativa al 5%? Si giustifichi la risposta, riportando anche l'ipotesi nulla, l'alternativa, l'espressione del p-value e il suo valore.

a2) Se **Promotion** è significativa, si fornisca l'interpretazione della stima del relativo coefficiente.

Di seguito l'output e i comandi. Si deve condurre un test sulla significatività del coefficiente di **PromotionYes**. Ipotesi nulla e alternativa sono rispettivamente

$$H_0: \beta_{\text{PromotionYes}} = 0 \quad H_1: \beta_{\text{PromotionYes}} \neq 0$$

Il p-value è

$$2P\left(T = \frac{|B_{\text{PromotionYes}}|}{SE_{\text{PromotionYes}}} > 7.303 \mid \beta_{\text{PromotionYes}} = 0\right)$$

Siccome il p-value è $1.14e-12$ più piccolo di 0.05, al 5% **Promotion** è significativa.

La stima del coefficiente di **PromotionYes** è 336.285. Fissate tutte le altre variabili, stimiamo che in media le vendite di libri con una forte campagna promozionale siano 336.285 maggiori delle vendite dei libri senza campagna promozionale forte.

```
>mod1<-lm(Sales ~ Price + Genre + Reviews + Promotion, data = df)
>summary(mod1)
```

Call:

```
lm(formula = Sales ~ Price + Genre + Reviews + Promotion, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-1399.92	-343.13	7.45	346.06	1641.12

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1002.997	185.380	5.411	9.82e-08 ***
Price	50.008	1.965	25.456	< 2e-16 ***
GenreMystery	303.926	67.823	4.481	9.24e-06 ***
GenreRomance	76.784	65.759	1.168	0.244
GenreScience Fiction	-277.905	63.085	-4.405	1.30e-05 ***
Reviews	195.265	41.914	4.659	4.10e-06 ***
PromotionYES	336.285	46.048	7.303	1.14e-12 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 512.5 on 493 degrees of freedom

Multiple R-squared: 0.6263, Adjusted R-squared: 0.6218

F-statistic: 137.7 on 6 and 493 DF, p-value: < 2.2e-16

Call:

b) Con riferimento al modello stimato, si costruisca l'intervallo di previsione al 90% per le vendite di un romanzo (**Genre=Romance**) senza forte campagna promozionale (**Promotion=NO**), prezzo uguale a 30 (**Price=30**) e voto medio delle recensioni dei lettori uguale a 4 (**Reviews=4**).

l'intervallo di previsione al 90% per le vendite di un romanzo (**Genre=Romance**) senza forte campagna promozionale (**Promotion=NO**), prezzo uguale a 30 (**Price=30**) e voto medio delle recensioni dei lettori uguale a 4 (**Reviews=4**) è (2511.966,4210.215).

```
>newdata=data.frame(Genre="Romance",Price=30,Promotion="NO",Reviews=4) >
predict(mod1,newdata=newdata,interval = "prediction",level=0.9)
      fit      lwr      upr
1 3361.09 2511.966 4210.215
```

c) Possiamo ritenere che **Genre** sia significativa all'1%? Si giustifichi la risposta riportando anche l'ipotesi nulla e quella alternativa del test, il valore della statistica test e la sua distribuzione sotto l'ipotesi nulla.

Si deve condurre un test F parziale. Ipotesi nulla e alternativa sono rispettivamente

$$H_0: \beta_{Mystery} = \beta_{Romance} = \beta_{Science Fiction} = 0 \quad H_1: \text{almeno un coefficiente} \neq 0$$

Il valore della statistica test è 27.89 e la sua distribuzione sotto l'ipotesi nulla è una distribuzione F con 3 e 493 gradi di libertà.

Siccome il p-value è 2.2e-16, minore di 0.01, possiamo concludere che **Genre** è significativa all' 1%.

```
> mod_ridotto=lm(Sales~Price+Reviews+Promotion,data=df)
> anova(mod_ridotto,mod1)
Analysis of Variance Table

Model 1: Sales ~ Price + Reviews + Promotion
Model 2: Sales ~ Price + Genre + Reviews + Promotion
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1     496 151492669
2     493 129512431   3   21980238 27.89 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

d) Si riporti la percentuale della variabilità totale di **Sales** che il modello non spiega.

Il modello non spiega il 37.37% della variabilità di **Sales** (1-R-squared=1-0.6263=0.3737).

Esercizio 3 (5 punti)

a) Si assuma che **Price** abbia una distribuzione normale nella popolazione di tutti i libri venduti negli anni in considerazione. Si costruisca un intervallo di confidenza al 99% per il prezzo medio; si arrotondino gli estremi alla seconda cifra decimale.

L'intervallo di confidenza al 99% per la media di **Price** nella popolazione è (29.30, 32.00).

```
> t.test(df$Price, conf.level=0.99)

One Sample t-test

data: df$Price
t = 58.551, df = 499, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
99 percent confidence interval:
 29.29528 32.00229
sample estimates:
mean of x
 30.64878
```

b) C'è evidenza empirica sufficiente per affermare, al livello 0.01, che meno del 25% dei libri di tutta la popolazione sia un romanzo (**Genre=Romance**)? Si giustifichi la risposta riportando ipotesi nulla e alternativa e la regione di rifiuto.

Si deve condurre un test sulla proporzione p di libri che, nella popolazione, sono romanzi. Ipotesi nulla e alternativa sono rispettivamente

$$H_0: p = 0.25 \quad H_1: p < 0.25$$

La regione di rifiuto all'1% è:

$$R_{0.01}: Z = \frac{\hat{P} - 0.25}{\sqrt{\frac{0.25 \cdot (1 - 0.25)}{500}}} < -z_{0.01} = -2.326348$$

dove $z_{0.01} = \text{qnorm}(1 - 0.01)$.

La proporzione campionaria osservata si ottiene come segue

```
> tab = table(df$Genre)
> prop.table(tab)
Fiction Mystery Romance Science Fiction
0.244    0.216    0.244    0.296
```

$\hat{p} = 0.244$, per cui il valore della statistica test è

$$\frac{\hat{p} - 0.25}{\sqrt{\frac{0.25 \cdot (1 - 0.25)}{500}}} = \frac{0.244 - 0.25}{\sqrt{\frac{0.25 \cdot (1 - 0.25)}{500}}} = -0.3098387$$

Siccome -0.3098387 è maggiore di -2.326348 , non si rifiuta. All'1% non c'è evidenza sufficiente per concludere che meno del 25% dei libri sono romanzi (**Genre=Romance**).

c) Con riferimento al problema di verifica di ipotesi del precedente punto b), si scriva cosa rappresenta l'errore di seconda specie.

L'errore di seconda specie consiste nel non rifiutare l'ipotesi nulla quando è vera. In questo caso l'errore di seconda specie consiste nel concludere che non c'è evidenza empirica sufficiente per affermare che meno del 25% dei libri sono romanzi, quando invece meno del 25% dei libri sono romanzi.